

Università degli Studi di Salerno
Corso di Laurea in Informatica

Machine Learning

Anno Accademico 2025/2026

Report di progetto

CARVAL

L'intelligenza artificiale al servizio della valutazione delle auto usate

Autore

Ferdinando Ranieri

Docenti

Prof. Giuseppe Polese
Prof.ssa Loredana Caruccio

Indice

1. Scenario, problema e task analizzato

1.1 Contesto

L'intelligenza artificiale e il Machine Learning stanno assumendo un ruolo sempre più rilevante in numerosi settori, incluso quello della valutazione automobilistica. L'analisi automatizzata dei veicoli consente di ridurre l'incertezza e migliorare i processi decisionali per venditori, acquirenti e istituzioni finanziarie.

L'applicazione di un modello predittivo per la valutazione delle auto presenta però alcune criticità di fondo, comuni a molti problemi di ML su dati reali: la qualità e la disponibilità dei dati, che condizionano fortemente le prestazioni ottenibili, e l'explainability, ossia la necessità di poter spiegare all'utente finale come ciascuna caratteristica influenzi la stima prodotta.

1.2 Il problema affrontato

L'obiettivo del progetto è sviluppare un sistema di apprendimento supervisionato in grado di predire il prezzo di un'auto usata sulla base delle sue caratteristiche, sfruttando l'esperienza maturata da un dataset storico di transazioni reali. Il progetto nasce dall'esigenza pratica di stimare in modo oggettivo il valore di mercato di un veicolo, in un contesto in cui le valutazioni tra concessionari e privati sono spesso disomogenee e poco trasparenti.

Per una modellazione più completa del problema, si è scelto di affrontarlo da due prospettive complementari:

- regressione: il modello predice il prezzo esatto del veicolo;
- classificazione: il prezzo viene discretizzato in fasce di valore (es. 0–5.000€, 5.000–10.000€, ecc.) e il modello impara ad assegnare l'auto alla fascia corretta.

Affrontare lo stesso problema con due formulazioni diverse consente di confrontare approcci e metriche di valutazione differenti, e di dimostrare padronanza di entrambe le famiglie di tecniche.

1.3 Utenti e casi d'uso

Il sistema è pensato per rispondere alle esigenze di più tipologie di utenti: acquirenti di auto usate, che possono verificare se il prezzo richiesto è in linea con il mercato; venditori privati e concessionari, che possono ottenere una stima realistica per fissare un prezzo competitivo; compagnie assicurative, che possono impiegare il sistema per stimare il valore residuo dei veicoli. L'idea di fondo è ridurre l'asimmetria informativa tra venditori e acquirenti attraverso una valutazione data-driven.

A supporto pratico del modello è stata inoltre sviluppata una semplice interfaccia web (Streamlit) che permette di inserire le caratteristiche di un veicolo e ottenere una stima immediata del suo valore; tale interfaccia non rappresenta una quotazione ufficiale, ma un supporto alla decisione.

2. Il dataset utilizzato e le sue caratteristiche

2.1 Provenienza e raccolta dei dati

Il dataset è stato reperito dalla piattaforma Kaggle ("Used Car Auction Prices", <https://www.kaggle.com/datasets/tunguz/used-car-auction-prices>). Si è preferito un dataset pubblico già strutturato, anziché una raccolta autonoma tramite web scraping, per garantire la riproducibilità degli esperimenti ed evitare le problematiche legali e di manutenzione tipiche della raccolta dati autonoma.

Il dataset presenta comunque dei limiti che vanno tenuti in considerazione nell'interpretazione dei risultati: copre esclusivamente il mercato nord-americano fino al 2015, quindi il modello è addestrato su informazioni storiche e non cattura necessariamente le dinamiche di mercato più recenti o di altri paesi.

2.2 Struttura del dataset

Il dataset di partenza è costituito da 558.811 osservazioni descritte da 16 caratteristiche, tra cui: anno di produzione, marca, modello, allestimento, tipo di carrozzeria, trasmissione, VIN, stato di registrazione, venditore, condizione del veicolo, chilometraggio, colore esterno e interno, MMR (valore di mercato storico), prezzo di vendita (target) e data di vendita.

Le principali statistiche descrittive delle variabili numeriche sono riassunte in Tabella 1.

Caratteristica	Count	Media	Std	Min	Max
year	558.811	2010,04	3,97	1982	2015
condition	547.017	3,42	0,95	1,0	5,0
odometer	558.717	68.323,20	53.397,75	1,0	999.999
mmr	558.811	13.769,32	9.679,87	25,0	182.000
sellingprice	558.811	13.611,26	9.749,66	1,0	230.000

Tabella 1: statistiche descrittive delle caratteristiche numeriche del dataset originale.

2.3 Analisi della correlazione e problema del data leakage

La matrice di correlazione (Figura 1) evidenzia una correlazione molto elevata tra la variabile mmr e il target sellingprice.




Figura 1: matrice di correlazione delle caratteristiche numeriche.

Tale correlazione è il sintomo di un rischio di data leakage: mmr è un indicatore di mercato calcolato con informazioni sostanzialmente coincidenti con il prezzo di vendita, quindi non sarebbe disponibile in una situazione

reale di stima a priori. Per questo motivo la caratteristica è stata esclusa fin da subito dal set di feature utilizzate per l'addestramento.

2.4 Distribuzioni e relazione con il target

Di seguito sono riportate le distribuzioni delle principali variabili numeriche del dataset.




Figura 2a: distribuzione dell'anno di produzione.




Figura 2b: distribuzione della condizione del veicolo.




Figura 2c: distribuzione del chilometraggio.




Figura 2d: distribuzione del prezzo di vendita (target).

Lo studio della variazione del target rispetto ad alcune variabili chiave ha permesso di individuare pattern di mercato utili in fase di modellazione.




Figura 3a: condizione del veicolo vs prezzo di vendita.



Figura 3b: anno di produzione vs prezzo di vendita.




Figura 3c: mmr vs prezzo di vendita.

Dalla Figura 3a emerge che il prezzo cresce al crescere del punteggio di condizione; dalla Figura 3b si osserva un andamento crescente a partire dal 1995; dalla Figura 3c la relazione tra mmr e prezzo risulta pressoché coincidente con la bisettrice del piano, confermando quantitativamente il rischio di data leakage discusso in precedenza.

3. Issue analizzate, soluzioni proposte e scelte di progettazione

3.1 Rumore e ambiguità nei dati

Un'analisi preliminare ha evidenziato diverse fonti di rumore nei dati grezzi. Uno stesso marchio automobilistico compariva sotto denominazioni diverse (es. 'mercedes', 'mercedes-b', 'mercedes-benz'); tali varianti sono state consolidate in un'unica forma standard tramite un mapping esplicito. In alcuni campioni il valore di allestimento (trim) coincideva col valore di modello: in questi casi il valore è stato sostituito con la stringa 'base'. Infine, i valori poco informativi nelle variabili di colore (es. il simbolo "-") sono stati trattati come dati mancanti.

La variabile trim presentava inoltre un'elevata cardinalità e variabilità lessicale: i valori sono stati raggruppati in categorie semantiche più ampie (base, special edition, sport, touring, luxury, other). Un raggruppamento analogo è stato applicato alla variabile body (sedan, suv, hatchback, van, coupé, cabriolet, station wagon, pickup, other), riducendo la dimensionalità senza perdere informazione rilevante.

3.2 Rimozione di feature ridondanti o irrilevanti

Sono state rimosse le seguenti caratteristiche, ritenute semanticamente irrilevanti o dannose per il task predittivo:

- mmr, per il rischio di data leakage discusso in precedenza;
- vin, codice univoco che non consente al modello di apprendere pattern generalizzabili;
- seller, ritenuto non informativo ai fini della predizione del prezzo;
- saledate, poiché non si è scelto di trattare esplicitamente l'informazione temporale;
- state, per garantire che il modello non sia vincolato ai confini geografici di registrazione.

Inoltre, per garantire la coerenza del dataset, sono stati esclusi i campioni con prezzo inferiore a 500€ (valori non realistici) e le marche con meno di 500 osservazioni complessive, in quanto insufficienti per un apprendimento affidabile.

3.3 Gestione dei valori mancanti

La Figura 4 mostra la quantità di valori nulli per ciascuna caratteristica nella versione iniziale del dataset.




Figura 4: valori nulli per caratteristica.

La strategia di imputazione adottata evita l'uso indiscriminato di medie/mode globali, che introdurrebbe bias, preferendo invece un'imputazione contestuale: per le variabili categoriche (es. carrozzeria, trasmissione) i valori mancanti sono sostituiti con la moda calcolata all'interno dello stesso modello di veicolo; per colorazione e colore interni la moda è calcolata per marca; per le variabili numeriche (condizione, chilometraggio) si utilizza la media calcolata per anno di produzione, assumendo che veicoli di età simile abbiano caratteristiche simili. Non sono stati riscontrati duplicati residui dopo le fasi di pulizia.

3.4 Scaling ed encoding delle variabili categoriche

Le variabili categoriche non possono essere utilizzate direttamente dai modelli di ML. Per la variabile trasmissione, binaria (manuale/automatico), è stato sufficiente un label encoding. Per le variabili categoriche ad alta cardinalità è stato invece adottato il CatBoost Encoding, che integra i vantaggi del target encoding introducendo un parametro di regolarizzazione α che bilancia la statistica locale della categoria con la media globale del target, riducendo il rischio di overfitting sulle categorie rare rispetto a un target encoding classico e la crescita di dimensionalità tipica del one-hot encoding.

Per portare le variabili numeriche sullo stesso dominio si è applicata la standardizzazione (z-score normalization), evitando che le feature con scale più ampie monopolizzino l'apprendimento del modello.

3.5 Rimozione degli outlier

Gli outlier possono distorcere in modo significativo l'apprendimento di un modello di ML. Sono state considerate outlier, e quindi rimosse, le osservazioni con un valore assoluto di z-score superiore a 3 sulle variabili numeriche rilevanti.

3.6 Feature engineering e selezione delle feature

Anziché utilizzare direttamente l'anno di produzione, è stata calcolata l'età del veicolo come differenza tra l'anno di riferimento (2015) e l'anno di produzione, rendendo la feature più direttamente interpretabile rispetto al prezzo. È stata inoltre applicata una selezione delle feature basata sulla varianza: le caratteristiche con varianza inferiore alla soglia 0,1 sono state rimosse, in quanto poco informative per il modello.

3.7 Bilanciamento delle classi (task di classificazione)

Per il task di classificazione il prezzo è stato discretizzato in cinque fasce (0–5.000€, 5.000–10.000€, 10.000–14.000€, 14.000–20.000€, 20.000€+), scelte per riflettere fasce di mercato intuitive piuttosto che quantili puramente statistici. L'analisi della distribuzione delle classi (Figura 5) ha mostrato una forte disparità tra la classe maggioritaria e le classi minoritarie.




Figura 5a: distribuzione delle classi di prezzo prima del bilanciamento.




Figura 5b: incidenza percentuale delle classi di prezzo.

Per mitigare lo squilibrio è stata adottata la tecnica di oversampling SMOTE (Synthetic Minority Over-sampling Technique), che genera campioni sintetici per le classi minoritarie interpolando tra osservazioni esistenti, riducendo il rischio che il modello impari a favorire quasi esclusivamente la classe dominante.

3.8 Selezione e giustificazione del modello

È stato scelto il RandomForest (Regressor per il task di regressione, Classifier per la classificazione) per la sua capacità di modellare relazioni non lineari tra le variabili senza richiedere l'assunzione di una forma funzionale esplicita, a differenza ad esempio della regressione lineare. Il prezzo di un'auto è influenzato da molteplici fattori (anno, chilometraggio, marca, modello, condizione, ecc.) che interagiscono in modo complesso; un metodo di

ensemble learning basato su alberi decisionali è in grado di catturare queste interazioni tramite bootstrap sampling, addestramento di alberi su sottoinsiemi diversi con selezione casuale delle feature ad ogni split, e infine aggregazione dei risultati (media per la regressione, voto di maggioranza per la classificazione).

La scelta degli iperparametri è stata guidata dalla necessità di bilanciare accuratezza, costo computazionale e rischio di overfitting: `n_estimators=300`, `max_features=sqrt(n_features)`, `min_samples_split=10`, `min_samples_leaf=4`, `bootstrap=True`, `random_state=20`, `criterion=squared_error` per la regressione e gini per la classificazione. Il valore di `max_depth` è stato scelto analizzando l'andamento della validation loss/accuracy al crescere della profondità (Figura 6): `max_depth=18` per la regressione e `max_depth=20` per la classificazione, oltre i quali non si osservano miglioramenti significativi ma solo un maggior rischio di overfitting.




Figura 6a: andamento della validation loss (MAE/MSE) al variare di `max_depth` – regressione.




Figura 6b: andamento della validation accuracy al variare di `max_depth` – classificazione.

Nota: non essendo obbligatorio l'uso dei soli modelli visti a corso, si segnala che le tecniche di encoding (CatBoost) e di bilanciamento (SMOTE) qui adottate estendono il set di strumenti standard, e sono state descritte nel dettaglio proprio per motivarne l'utilizzo e dimostrarne la corretta comprensione.

4. Analisi delle prestazioni

4.1 Metodologia di validazione

Per evitare i risultati distorti di un singolo train/test split, la valutazione è stata condotta con k-fold cross validation (k=10): ad ogni iterazione un fold diverso viene usato come test set, mentre le operazioni di preprocessing (imputazione, encoding, scaling, rimozione outlier, oversampling) vengono ricalcolate esclusivamente sul training set del fold corrente, per evitare data leakage tra training e test.

4.2 Risultati – task di classificazione

Le metriche standard derivate dalla matrice di confusione (precision, recall, f1-score, accuracy) sono riportate fold per fold in Tabella 2.

Fold	Accuracy	Precision	Recall	F1-score
1	0.7599	0.7594	0.7599	0.7589
2	0.7614	0.7605	0.7614	0.7600
3	0.7604	0.7595	0.7604	0.7592
4	0.7612	0.7605	0.7612	0.7601
5	0.7611	0.7606	0.7611	0.7602
6	0.7629	0.7623	0.7629	0.7618
7	0.7609	0.7602	0.7609	0.7597
8	0.7647	0.7640	0.7647	0.7636
9	0.7613	0.7607	0.7613	0.7602
10	0.7626	0.7618	0.7626	0.7612

Tabella 2: metriche di validazione per il task di classificazione.

Le prestazioni sono stabili tra i fold (accuracy tra 0,7599 e 0,7647), a indicare una buona capacità di generalizzazione. È inoltre significativo che precision, recall e f1-score restino molto vicini all'accuracy in ogni fold: se una o più classi minoritarie fossero sistematicamente penalizzate, il recall medio si discosterebbe maggiormente dall'accuracy. Questo è in buona parte un effetto atteso dell'oversampling SMOTE applicato in training.




Figura 7a: matrice di confusione – primo fold.




Figura 7b: matrice di confusione – decimo fold.




Figura 8: importanza delle caratteristiche – classificazione.

4.3 Risultati – task di regressione

Le metriche di errore per il task di regressione sono riportate fold per fold in Tabella 3.

Fold	MAE	MSE	RMSE	MAPE
1	1523.73	7924227.41	2815.00	16.7%
2	1550.91	8283304.95	2878.07	16.7%
3	1525.65	8973708.40	2995.61	16.8%
4	1530.21	7879336.22	2807.01	16.7%
5	1539.08	8816325.53	2969.23	16.5%
6	1549.62	8735598.15	2955.60	16.5%
7	1557.97	8581746.01	2929.46	16.8%
8	1544.62	8156220.90	2855.91	16.7%
9	1527.13	7820900.66	2796.59	17.0%
10	1531.88	8398450.02	2898.01	16.6%

Tabella 3: metriche di validazione per il task di regressione.




Figura 9: importanza delle caratteristiche – regressione.

4.4 Analisi dei tipi di errore

Oltre alle metriche aggregate, è utile analizzare la natura degli errori commessi dal modello.

Classificazione

Le classi di prezzo utilizzate sono ordinali per costruzione (derivano dalla discretizzazione di una variabile continua). Ciò rende atteso che gli errori residui si concentrino soprattutto tra classi adiacenti (ad esempio tra la fascia 10.000–14.000€ e quella 14.000–20.000€), poiché un veicolo con prezzo vicino al confine tra due fasce può essere ragionevolmente scambiato con la fascia limitrofa; è invece molto meno probabile una confusione tra classi distanti (es. 0–5.000€ e 20.000€+), il cui profilo di feature (età, chilometraggio, condizione) è tipicamente molto diverso. Le matrici di confusione di Figura 7 permettono di verificare puntualmente questo pattern osservando la concentrazione dei valori sulla diagonale principale e sulle sue immediate adiacenze.

Regressione

Confrontando MAE e RMSE in Tabella 3 emerge un rapporto RMSE/MAE prossimo a 1,85–1,95 in tutti i fold. Poiché l'RMSE penalizza quadraticamente gli errori più grandi mentre il MAE li pesa in modo lineare, un rapporto così superiore a 1 indica che l'errore non è distribuito in modo uniforme: la maggior parte delle predizioni ha un errore contenuto, ma esiste un sottoinsieme di veicoli (verosimilmente quelli con combinazioni di caratteristiche meno rappresentate nel dataset, es. marche/modelli più rari o condizioni anomale) su cui il modello commette errori assoluti considerevolmente più grandi.

Il MAPE, attestato intorno al 16–17%, va inoltre letto insieme al MAE: a parità di errore assoluto in euro, l'errore percentuale è necessariamente più marcato sulle auto di fascia di prezzo più bassa (dove lo stesso scarto assoluto rappresenta una quota maggiore del valore del veicolo) rispetto alle auto di fascia alta. Questo suggerisce che il modello sia relativamente più preciso in termini assoluti sui veicoli economici, ma relativamente meno preciso in termini percentuali proprio su quella stessa fascia.

5. Considerazioni finali e sviluppi futuri

Il progetto Carval ha mostrato come tecniche di Machine Learning standard, affiancate da un'attenta fase di data understanding e data preparation, permettano di ottenere un sistema di stima del prezzo di auto usate con prestazioni stabili e generalizzabili, sia in ottica di regressione sia di classificazione. Le criticità tipiche di un dataset reale (rumore nelle categorie, valori mancanti, outlier, rischio di data leakage, sbilanciamento delle classi)

sono state affrontate con soluzioni motivate e documentate, e le scelte di modellazione (RandomForest, iperparametri, encoding, bilanciamento) sono state giustificate sulla base delle caratteristiche del problema.

Il sistema presenta comunque margini di miglioramento. Sul fronte dei dati, l'integrazione di fonti più recenti e relative a mercati diversi da quello nord-americano renderebbe il modello più generale, mentre l'aggiunta di informazioni più granulari (storico manutenzioni, incidenti, numero di proprietari precedenti) potrebbe affinare ulteriormente le stime. Sul fronte del modello, per vincoli di tempo non è stato possibile sperimentare in modo estensivo algoritmi alternativi (es. gradient boosting) né tecniche di ottimizzazione automatica degli iperparametri (es. algoritmi genetici o ricerca bayesiana), che rappresentano naturali sviluppi futuri per migliorare ulteriormente l'accuratezza del sistema.