

UNIVERSITÀ DEGLI STUDI DI SALERNO

Corso di Laurea in Informatica · Machine Learning · A.A. 2025/2026

CARVAL

L'intelligenza artificiale al servizio della valutazione delle auto usate

Autore Ferdinando Ranieri

Docenti Prof. Giuseppe Polese, Prof.ssa Loredana Caruccio

Obiettivo del progetto e metodologia

Cosa vogliamo ottenere

Sviluppare un sistema di Machine Learning in grado di predire il prezzo di un'automobile usata a partire dalle sue caratteristiche, affrontando il problema sia come task di regressione (prezzo esatto) sia di classificazione (fascia di prezzo).

- Supportare venditori e acquirenti con una stima oggettiva
- Ridurre l'asimmetria informativa nel mercato dell'usato
- Confrontare due formulazioni complementari dello stesso problema

Metodologia · CRISP-DM

- 1 Business Understanding
- 2 Data Understanding
- 3 Data Preparation
- 4 Modeling
- 5 Evaluation
- 6 Deployment

Lo scenario e il problema



Il problema

Le valutazioni del prezzo di un'auto usata tra privati e concessionari sono spesso disomogenee e poco trasparenti.



Cosa offriamo

Supporto a venditori e acquirenti, riduzione dei tempi di stima, maggiore trasparenza nelle transazioni.



Come misuriamo il successo

Metriche standard: MAE / MAPE per la regressione, Accuracy / Precision / Recall / F1 per la classificazione.

Il dataset



558.811

osservazioni

16

caratteristiche originali

Kaggle • Used Car Auction Prices
Mercato nord-americano, dati fino al 2015

Le caratteristiche principali

Anno produzione

Marca

Modello

Allestimento

Carrozzeria

Trasmissione

Condizione

Chilometraggio


Colorazione

Colore interni

MMR

Prezzo (target)

Correlazione e data leakage






Il predittore "leaky": mmr

La variabile mmr correla al 98% con il target sellingprice: è un indicatore di mercato calcolato con informazioni sostanzialmente coincidenti con il prezzo di vendita.

In una situazione reale di stima a priori questo dato non sarebbe disponibile: per questo è stato escluso fin da subito dal set di feature utilizzate per l'addestramento.

mmr ↔ sellingprice: corr. 0,98

Distribuzioni e relazione col target




Il prezzo cresce con la condizione e con gli anni più recenti (in particolare dal 1995); la relazione con mmr è quasi perfettamente lineare, a conferma quantitativa del rischio di data leakage.

Pulizia dei dati e valori mancanti



Rumore e ambiguità

- Denominazioni multiple dello stesso marchio consolidate (es. mercedes / mercedes-benz)
- Trim coincidente col modello → sostituito con 'base'
- Trim e body raggruppati in categorie semantiche (base, sport, luxury, suv, coupé...)
- Simboli poco informativi (es. '-') trattati come mancanti



Imputazione contestuale (non globale): moda per modello/marca, media per anno di produzione.

Rimozione degli outlier



Perché rimuoverli

Osservazioni anomale possono distorcere in modo significativo l'apprendimento di un modello, spostando i confini decisionali verso valori non rappresentativi del mercato reale.

Z-score normalizzato

$|z| > 3 \rightarrow$ osservazione rimossa

applicato a tutte le variabili numeriche del dataset preparato



Senza rimozione outlier

il modello tende ad adattarsi eccessivamente a pochi casi estremi, peggiorando la generalizzazione sulla maggioranza dei veicoli "tipici".

Feature engineering e selezione



Età del veicolo

età = anno di riferimento (2015) - anno di produzione

Una feature derivata più direttamente interpretabile rispetto al prezzo dell'anno grezzo di produzione.

Selezione basata sulla varianza

Le feature con varianza inferiore a una soglia prestabilita vengono scartate perché poco informative per il modello.

Rimosse anche le feature non informative

- mmr (data leakage)
- vin (identificativo univoco)
- seller (non informativo)
- saledate (non usata esplicitamente)
- state (indipendenza geografica)

Encoding e normalizzazione



CatBoost Encoding

Per le variabili categoriche ad alta cardinalità (marca, modello...). Integra i vantaggi del target encoding con un parametro di regolarizzazione α che bilancia la statistica locale con la media globale del target.



Riduce l'overfitting sulle categorie rare rispetto a un target encoding classico, evitando anche l'esplosione dimensionale del one-hot encoding.



Standardizzazione (z-score)

Le variabili numeriche vengono portate sullo stesso dominio, evitando che le feature con scale più ampie (es. chilometraggio) monopolizzino l'apprendimento rispetto a quelle con range più piccoli (es. condizione).

Bilanciamento delle classi (classificazione)



5 fasce di prezzo: 0-5k • 5-10k • 10-14k • 14-20k • 20k+ € — scelte per riflettere fasce di mercato intuitive.



SMOTE

Synthetic Minority Over-sampling Technique

Genera campioni sintetici per le classi minoritarie interpolando tra osservazioni esistenti, evitando che il modello favorisca la classe dominante.

Perché Random Forest



Ensemble di alberi decisionali

Il prezzo di un'auto dipende da molti fattori (anno, km, marca, condizione...) che interagiscono in modo non lineare — non adatto a un modello che assume una forma funzionale esplicita come la regressione lineare.

1 Campionamento

2 Addestramento

3 Aggregazione

Iperparametri scelti

n_estimators

300

min_samples_split

10

bootstrap

True

max_features

$\sqrt{n_features}$

min_samples_leaf


4

criterion

squared_error / gini

Nota: dimostrazione di padronanza anche di tecniche extra-corso (CatBoost Encoding, SMOTE) documentate nel dettaglio.

Scelta della profondità (max_depth)



Regressione:


max_depth = 18

Oltre questa soglia non si osservano miglioramenti significativi sulla validation loss, solo un maggior rischio di overfitting.



Classificazione: **max_depth = 20**

Risultati — classificazione



Matrice di confusione — primo fold di 10

Metriche medie (10 fold)

Accuracy	76,2%
Precision	76,1%
Recall	76,2%
F1-score	76,0%



Prestazioni stabili

Accuracy tra 75,99% e 76,47% su tutti i fold.
Precision, recall e f1 restano vicini all'accuracy grazie all'oversampling SMOTE in training.


Matrice di confusione — primo fold di 10

Le classi di prezzo sono discretizzate in 5 fasce (0-5k, 5-10k, 10-14k, 14-20k, 20k+ €), bilanciate in training con SMOTE.

Risultati — regressione

Fold	MAE	MSE	RMSE	MAPE
1	1.523,73	7.924.227	2.815,00	16,7%
2	1.550,91	8.283.305	2.878,07	16,7%
5	1.539,08	8.816.326	2.969,23	16,5%
8	1.544,62	8.156.221	2.855,91	16,7%
10	1.531,88	8.398.450	2.898,01	16,6%

Media sui 10 fold: MAE $\approx$ 1.538€ • RMSE $\approx$ 2.905€ • MAPE $\approx$ 16,7%



Feature importance — regressione: età, chilometraggio e modello sono i predittori più rilevanti.

Analisi dei tipi di errore



Classificazione

Le classi di prezzo sono ordinali per costruzione: è atteso che gli errori si concentrino tra classi adiacenti (es. 10-14k€ confusa con 14-20k€), mentre è raro confondere classi lontane (0-5k€ con 20k€+), il cui profilo di feature è molto diverso.

Verificabile direttamente sulla matrice di confusione: valori concentrati sulla diagonale e sulle celle immediatamente adiacenti.



Regressione

Il rapporto $RMSE/MAE \approx 1,85-1,95$ in tutti i fold indica un errore non uniforme: la maggioranza delle stime ha un errore contenuto, ma un sottoinsieme di veicoli (marche/modelli rari, condizioni anomale) genera errori assoluti molto più grandi.

Il MAPE (~16-17%) è relativamente più marcato sulle auto di fascia di prezzo bassa: a parità di errore assoluto in euro, pesa di più in percentuale su un veicolo economico.

Dall'esperimento all'utilizzo pratico



Interfaccia Streamlit

Per rendere il modello utilizzabile praticamente è stata sviluppata una semplice applicazione web: l'utente inserisce le caratteristiche di un veicolo (marca, modello, anno, condizione, chilometraggio...) e ottiene una stima immediata del prezzo.

Non rappresenta una quotazione ufficiale, ma un supporto alla decisione basato sui pattern appresi dal modello.

Considerazioni finali e sviluppi futuri



Ottimizzazione automatica

Algoritmi genetici o ricerca bayesiana per il tuning degli iperparametri, oggi scelti in modo empirico.



Dataset più ampio

Dati più recenti e relativi a mercati diversi da quello nord-americano, con informazioni più granulari.



Modelli alternativi

Sperimentazione di algoritmi di gradient boosting, a discapito però dell'explainability attuale.



Grazie per l'attenzione

Carval — L'intelligenza artificiale al servizio della valutazione delle auto usate

Ferdinando Ranieri